

织物缺陷检测：数据勘误与 RT-DETR 验证报告

旧口径勘误 · 三数据体系严格自评 · Transformer 路线验证

2026-08 修订版 (Phase 4) · 全部数值与仓库脚本可复现

数据集体系：V1 / V2 / V3 (严格 self-val, 禁跨集比较)

说明一：报告目标与正式口径

1. **报告对象**：17 类织物缺陷检测 (yolo11s/RT-DETR 训练侧探索)，交付训练权重，禁用推理端手段 (TTA / 高分辨率推理 / 集成)。
2. **正式口径**：self-val (自集验证) + $\text{conf}@0.25$ + $\text{IoU} \geq 0.5$ + 17 类宏平均；推理分辨率 1280 (640 训练模型仅按 640 推理)。
3. **数据体系**：V1 / V2 / V3 三套划分互不混用，各体系内严格自评；跨体系数值 (如 V1 的 0.7565 vs V3 的 0.6038) 直接比较即为错误。
4. **数值纪律**：全部正式数值与 `scripts/eval_scoring.py` (仓库内) 一致；已用 004 / 076 / 097 三个锚点模型复算验证，与历史记录逐位吻合 (见附录)。

说明二：数值评级规则（每表来源列与页脚注）

5. **A 级（磁盘可核）**：数值存于仓库文件（report_retest_selfval_conf025.csv / outputs/eval_scoring/*/scoring_report.txt）或本次复算输出，可逐行核对。
6. **S 级（评测输出记录）**：权重已清理，仅存当时 eval_scoring.py 输出；其 maxR 与磁盘报告一致（如 096 的 0.8971）。
7. **B 级（会话记录）**：V3 体系全部实验（079-093）——v3 数据集、权重、评测报告文件 均已被环境清理，仅存当时评测输出记录；**仅供内部方向判断**，禁止与 A/S 级排序比较，正式引用前需重建 V3 环境复核。
8. **对比完整性**：每组表格只列同一体系内的实验；跨体系只作趋势说明，不作排序。
9. **F1 定义**： $F1@0.25 = 2 \cdot R \cdot P / (R + P)$ （同一 conf 处计算），全表统一。

旧报告数据勘误（01/02/03 版）

旧表述	问题	正确值（本报告口径）
02：018/022 宏召回 0.8836 / 0.8898，“分辨率杠杆 +0.06-0.08”	conf→0 兜底值（P≈0.02，堆框虚高）	018 = 0.5630 ；022 = 0.4266 —— 训练分辨率无正收益
02/03：057 “唯一正信号”（旧报 0.8175 / +1.2%）	兜底值 + v2 跨集泄漏	057 = 0.4824 （-9.2% vs 044 基线）
03：053 跨集 0.8095 / 004 跨集 0.8918	v2 val 与 v1 train 重叠 80.9%（泄漏）	053 = 0.5750；004 = 0.6140（self-val）
早前审计：080 曾报 0.6593	诊断脚本（r25 类）重复计数口径	080 = 0.6038（正式评分）
03 注意力实验表 009-017 数值混排	v1 / v2 划分分数并存“	009 = 0.4971（v1）；044 = 0.5316（v2）——分列，不可互比
03 结论“训练侧所有杠杆均无正收益”	该结论截止 057，未包含 RT-DETR 路线	RT-DETR-L@1280 = 0.7565， +13.5pp ，结论被推翻
03 第 10 页 “1280 推理 +0.06-0.08 / TTA 0.8461”	均为推理端手段（终局禁用）	保留为禁用证据；不参与交付排名

注：以上“问题值”均为旧报告真实输出，非笔误——由口径与泄漏导致；本表仅说明差异与正确值。

数据体系与实验索引

体系	训练图数	val 图数 / GT	划分方式	本报告包含实验
V1	1445	181 / 377	原始划分	001-019（部分）, 053, 056, 076, 078, 095, 096, 097
V2	1277	350 / 678	类分层重划分	044-049, 051, 052, 057
V3	1448	180 / 428	8:1:1 图级 + 类分层	079-093（B 级记录）

实验编号索引：

体系	编号
V1	004/008/019（yolo11s 基线）、053/056（yolo26s）、076/078（Kaggle）、095/096/097（RT-DETR）、095_inplace
V2	044（基线）、045-048（数据/预训练）、049（多尺度）、051/052（yolo10s/yolo26s）、057（cos）
V3	079-089（Aug 扫描）、091（P2）、092（EQLv2）、093（Seesaw）

注：V3 val 每类 GT ≥8（bd 72 / heidian 60），样本量约为 V1 val 的 1.6-1.9 倍；不同体系 val 难度不同，指标水平不具可比性。

V1 体系完整对比 (self-val: 181 图 / 377 GT)

实验	模型 / 配置	R@0.25	P@0.25	F1@0.25	maxR	来源
004	yolo11s @640 (基线)	0.6140	0.5453	0.5776	0.8197	A
019	yolo11s + cls_w @1280	0.6213	0.6239	0.6226	0.8149	A
008	yolo11s + randaug	0.6103	0.5661	0.5874	0.8466	A
053	yolo26s 200ep	0.5750	0.6383	0.6050	0.7826	A
056	yolo26s 200ep + cos	0.5891	0.6076	0.5982	0.7872	A
076	yolo11s Kaggle @1280	0.6353	0.4320	0.5143	0.8426	A
078	yolo11s + 增强池 @1280	0.6217	0.4185	0.5003	0.8504	S
095_inplace	yolo11s + 原位小池 @1280	0.5279	0.4307	0.4744	0.8979	S
095	RT-DETR-L @640	0.7070	0.4437	0.5453	0.8304	S
096	RT-DETR-L @1280	0.7565	0.4029	0.5258	0.8971	S
097	RT-DETR-L @1280 (显式 AdamW)	0.7137	0.3939	0.5076	0.8591	A

注：等级见“说明二”；096/097 复算数值见附录（096 权重已清理，仅剩评测记录与 maxR 磁盘佐证）。

V1 体系结论

1. **RT-DETR-L@1280 全链最强**: $R@0.25 = 0.7565$, 超 YOLO 最优 (019 = 0.6213) **+13.5pp**;
Transformer (去 NMS 的 DETR 解码器) 是本项目首个明确正收益架构。
2. **增强池无增益**: 076 (0.6353) 高于 019, 但 078 (+合成/放大池 0.6217) 反而低于 076 —— 池不平衡, 收益被稀释; 095_inplace (0.5279) 说明原位小池对 YOLO 本身有限。
3. **优化器陷阱**: ultralytics optimizer=auto 按 $lr_fit = 0.002 \times 5 / (4 + nc)$ 自动定 lr (nc=17 $\rightarrow$ 0.000476) 并**忽略用户 lr0**; 097 显式锁定 $1e-4$ 反而 -4.3pp (0.7565 $\rightarrow$ 0.7137)。
4. **无 NMS 架构在 V2 不成立** (见下页), 但在 V1 系 RT-DETR 成立——架构收益与环境相关, 不能跨体系套用。

V2 体系全重跑 (self-val: 350 图 / 678 GT)

实验	配置	R@0.25	P@0.25	结论	来源
044	yolo11s v2 (基线)	0.5316	0.5355	V2 标准线	A
045	v2 + test GT 并入	0.5476	0.5602	唯一正收益: +14% 数据量 分辨率无增益	S
046	v2 + 1280 过采样	0.5327	0.5732		S
047	046 无预训练	0.5327	0.5732	=046 (无效变量)	S
048	046 暖启动	0.5189	0.5218	同负	S
049	v2 + 多尺度	0.3574	0.6187	严重负收益 (-17.4pp)	A
051	yolo10s v2	0.4988	0.6866	双头架构难收敛	A
052	yolo26s v2	0.4759	0.6775	无 NMS 无优势	A
057	yolo26s v2 + cos	0.4824	0.6155	cos 仍负 (-9.2%)	A

结论：数据量（045）是 V2 内唯一正向；多尺度 / 过采样 / 无 NMS 架构全部 ≤ 基线。

V3 体系全扫描 (B 级记录 · 仅供内部方向)

V3 val: 180 图 / 428 GT; 下表为当时 eval_scoring 输出, 资产 (数据/权重/报告) 已清理。

实验	配置 (V3 self-val / 1280 / conf@0.25)	R@0.25	P@0.25	maxR
079	V3-A: 原图 + wavelet + contrast	0.5841	0.4180	0.8081
080	V3-B: 原图 + small 原位池	0.6038	0.3167	0.8700
081	small 2x (倍率减半)	0.5379	0.3163	0.8340
082	class gain 关闭	0.4371	0.4490	0.8232
083	cls 权重关闭	0.4293	0.3723	0.8318
084	area 权重关闭	0.3775	0.4176	0.8406
085	gain = 1.5	0.4634	0.3501	0.8372
086	V3-B + contrast 池	0.5385	0.2819	0.8196
087	box 7.5 → 10	0.5242	0.3004	0.8213
088	yolo11n @640	0.4056	0.5421	0.7719
089	mixup + cutmix	0.4708	0.2958	0.8496
091	P2 头 (4 头)	0.3982	0.2651	0.8194
092	EQLv2 (长尾)	0.3230	0.5450	0.8250
093	Seesaw (长尾)	0.4353	0.3944	0.7951

方向结论: 080 (small 原位池) 内部最优; 082-085 (增益开关) 确认加分项本就有限; 086 (+contrast) 反而伤 bd; 088@640 崩塌证明 V3 必须 1280; 091 (P2) /092/093 (长尾) 全负。

速度 (Item4) 与优化器实测

模型	@640	@1024	@1280	@3080 折算@1024	Item4 (≥30fps)
004 yolo11s	56.1	51.2	35.3	128.0	PASS
076 yolo11s (1280 训练)	61.0	47.8	33.8	119.5	PASS
095 RT-DETR-L @640	21.3	13.1	9.6	32.9	PASS (边缘)
096 RT-DETR-L @1280	19.5	11.9	9.8	29.7	FAIL (-0.3)
097 RT-DETR-L @1280	21.0	12.2	9.0	30.4	PASS (边缘)

- 说明：
- 1. 数值为 RTX 3060 实测定格；@3080 = ×2.5 TFLOPS 折算（近似），不同帧率单位 fps。
 - 2. yolo11s 全程宽裕（119+fps）；RT-DETR-L 三 run 全部紧贴 30fps 红线——Item4 与精度（096 = 0.7565）存在冲突，需目标机实测后取舍。
 - 3. 优化器：auto 实际 lr = $0.002 \times 5 / (4 + 17) = 0.000476$ （忽略 lr0）；后续 RT-DETR 建议显式 AdamW + lr0≈4.8e-4，避免“改 lr 无效”的假象。

数据集改进研究（一）：097 @最好点逐类 mAP

评估：RT-DETR-L (097) 在 V1 val (181 图 / 377 GT) @1280 全曲线评估；最好点 = 宏平均 F1 最大处，conf=0.548。全局：mAP50 = **0.6363**，mAP50-95 = 0.4328，best-F1 点 R=0.6494 / P=0.6581 / F1=0.6406（vs conf@0.25 的 R=0.7159 / P=0.3925）。

类	n	AP50	mAP@.5:.95	bestF1	R@best	P@best
lj	12	0.412	0.302	0.521	0.500	0.544
bd	44	0.290	0.071	0.383	0.318	0.481
heidian	39	0.268	0.117	0.411	0.359	0.481
wy	39	0.162	0.071	0.328	0.256	0.454
zyc	11	0.955	0.815	0.909	0.909	0.909
zmt	37	0.290	0.120	0.360	0.297	0.456
cq	17	0.605	0.357	0.645	0.588	0.714
zj	18	0.878	0.811	0.882	0.833	0.937
bj	22	0.626	0.325	0.732	0.682	0.789
jt	10	0.826	0.607	0.857	0.900	0.818
yy	2	0.995	0.845	0.996	1.000	0.993
bmss	44	0.349	0.161	0.441	0.386	0.514
zy	27	0.702	0.429	0.720	0.667	0.782
pd	20	0.886	0.701	0.865	0.800	0.941
HD	9	0.850	0.365	0.842	0.888	0.800
cy	16	0.818	0.494	0.786	0.687	0.917
jiaodai	10	0.905	0.766	0.952	1.000	0.909

弱类排序 (AP50 升序): wy 0.162 < heidian 0.268 < bd 0.290 $\approx$ zmtty 0.290 < bmss 0.349 < lj 0.412;
强类 (AP50 $\geq$ 0.80): zyc / yy / zj / jt / pd / HD / cy / jiaodai。

数据集改进研究（二）：GT 缺陷尺寸分布

V1 val 全部 377 GT 框尺寸统计（原图 2048 基准；S <32px / M 32-96px / L >96px）：

类	n	中位边长(px)	S%	M%	L%	AP50 (097)
lj	12	111	33	17	50	0.412
bd	44	15	100	0	0	0.290
heidian	39	12	97	3	0	0.268
wy	39	57	26	36	38	0.162
zyc	11	348	0	0	100	0.955
zmtty	37	160	11	14	76	0.290
cq	17	659	0	0	100	0.605
zj	18	981	0	0	100	0.878
bj	22	534	0	0	100	0.626
jt	10	479	0	0	100	0.826
yy	2	594	0	0	100	0.995
bmss	44	76	18	34	48	0.349
zy	27	540	0	0	100	0.702
pd	20	755	0	0	100	0.886
HD	9	576	0	0	100	0.850
cy	16	508	0	0	100	0.818
jiaodai	10	130	0	20	80	0.905

全局：S = 108 (28.6%)、M = 39、L = 230；中位边长 201px。 **尺寸-性能强关联**：中位边长 <80px 的类 (bd / heidian / wy / zmtty / bmss / lj) AP50 全部 ≤ 0.41 ；中位 >300px 的类 AP50 全部 ≥ 0.60 。小目标是数据集的第一短板。

数据集改进研究（三）：改进方向与预期

1. **小目标欠采样是根因**：377 GT 中 28.6%（108 个）为 <32px 小目标，且集中在 bd（100% S）/ heidian（97% S）/ wy（26% S）三类；1280 训练时这些缺陷仅 7-16px——训练-推理尺度失配（与 V3 阶段诊断一致）。
2. **wy 是隐藏短板**：此前只盯 bd/heidian；本表显示 wy（39 实例、26% S、弱纹理）AP50 = **0.162** 全场最低，且 maxR 仅 0.487（漏检多）——应纳入小目标/难例挖掘的第一梯队。
3. **数据改进动作**（训练侧，符合只交权重约束）：
 - ① 小目标原位池扩展到 wy/bmss（V3-B 已验证 bd/heidian 增益，扩类需重验）；
 - ② 尺寸分层过采样：S 类 $\geq 2\times$ 、M 类 $1.5\times$ （简单加权，不改变标注）；
 - ③ 弱纹理类（wy / bmss / zmty）对比度+小波增强（086 在 YOLO 为负，RT-DETR 未验证，需重试）；
 - ④ 难例挖掘补漏检框（wy maxR 0.487 / bmss 0.773 为最高收益区）。
4. **不再投入**：大目标类（zyc / yy / zj / jt / pd / HD / cy / jiaodai）AP50 ≥ 0.80 已饱和。
5. **验证体系**：数据集改进必须在 V3 体系（bd 72 / heidian 60 GT，弱类方差更小）验证，避免 V1 val 弱类 39-44 样本的噪声；同时新增 wy / bmss 的 V3 逐类基线。

数据集改进研究（四）：极小缺陷像素尺寸（2048 → 1280）

GT 框边长 (px)；1280 列 = 2048 × 0.625（等比例 letterbox）：

类	n	原图 2048 中位 (min-max)	1280 推理中位 (min-max)	判定
bd (白点)	44	15 (6-32)	9.4 (3.7-19.8)	超小
heidian (黑点)	39	12 (8-36)	7.4 (4.7-22.5)	超小
wy (污印)	39	57 (11-686)	35.5 (6.6-428.5)	跨尺度
bmss (表面损伤)	44	76 (17-1330)	47.6 (10.3-831.2)	跨尺度
lj (垃圾)	12	111 (8-747)	69.6 (5.0-466.9)	跨尺度
zmt (脏面条印)	37	160 (25-1242)	99.8 (15.3-776.0)	中大
jiaodai (胶带)	10	130 (59-146)	81.0 (36.8-90.9)	中大
HD (横档)	9	576 (399-789)	360 (249-493)	大目标 (非小缺陷)

关键事实：

- 1. **bd / heidian 是超小目标**：1280 推理下中位仅 9.4 / 7.4px——1280 输入经 32 倍下采样后 每个特征图单元格 = 40px，**目标比一个 cell 还小**，只可能在 P3/P4 高分辨率特征上残留信号，检测器天然弱（对应 AP50 0.29 / 0.27）。
- 2. **HD 不是小缺陷**（中位 576px，100% 大目标，AP50 0.85）——“hd”需与 heidian 区分，极小缺陷类是 **bd / heidian**。
- 3. **跨尺度类 (wy / bmss / lj)**：同一类内从 6px 到 1300px 都有 → 需尺度分桶增强，而非整体缩放。

数据集改进研究（五）：patch（原位小目标池）效果

V3 体系（B 级，yolo11s @1280）：

run	训练数据	R@0.25	maxR	ΔR@0.25	ΔmaxR
079	原图 + wavelet + contrast	0.5841	0.8081	—	—
080	079 + small 原位池 （131 图 ×4 光度变体）	0.6038	0.8700	+2.0pp	+6.2pp
081	080 但 small 池倍率 4x→2x	0.5379	0.8340	−6.6pp	−3.6pp

V1 体系逐类对照（bd / heidian）：


run	数据/架构	bd R@0.25	heidian R@0.25	bd AP50
076	yolo11s @1280（无 patch）	0.205	0.154	—
063	yolo11s + bdhd 合成池 @1280	0.4773	0.3333	—
097	RT-DETR-L @1280（无 patch）	0.500	0.410	0.290 / 0.268

效果结论：

- 1. **原位池有效**：V3 上 080 宏观 +2.0pp、maxR +6.2pp——小尺度正样本直接提升召回上限；
- 2. **池构成敏感**：081（倍率减半）-6.6pp → 原位尺度保持（不放大、不变换）是收益来源；
- 3. **合成池 vs 原位池**：063 合成池对 bd/hei 逐类增益大（0.205→0.4773 / 0.154→0.3333），但宏观受弱类挤占（078 < 076）；两者方向一致，可组合；
- 4. **RT-DETR 无池基线**：097 的 bd/hei 仍是最弱档（AP50 0.29 / 0.27）→ **原位池 × RT-DETR × V3 体系是下一步最高优先级组合。**

数据集改进研究 (六): 097 推理样图 vs GT —— 检出案例

条件: RT-DETR-L (097) @1280、conf=0.548 (最好点)。每图左 = GT 标注, 右 = 097 预测 (青色虚线, 含 conf); 同一裁剪区域。



bd 检出 (LZW_20250418_1845)



heidian 检出 (1021__0921)

大目标类检出
(100_DHW_20250103before)

观察: 小目标 (bd / heidian) 在最好点下可检出 (对应 bd $R@0.25=0.500$ 、hei 0.410), 但预测框与 GT 对齐度低、置信度分散; 大目标类框对齐良好。

数据集改进研究 (七): 097 推理样图 vs GT —— 漏检 / 误检

同条件: @1280、conf=0.548。每图左 = GT 标注 (橙色 = 漏检), 右 = 097 预测; 同一裁剪区域。



bd 漏检 (0_DHW_20250103)


heidian 漏检 (113__0921)

误检 FP (0_DHW_20250103)

观察: 漏检集中于极小 bd / heidian (1280 下 4-20px, 弱于特征图 cell 40px); 误检多为低置信同类噪声框。→ 印证数据集改进研究 (五): 需小目标原位池 + 难例挖掘, 并在 RT-DETR × V3 体系重验 (见 11c/11e)。

数据集改进研究 (八): **097 混淆矩阵 (conf=0.548)**

数据集改进研究 (八): 097 混淆矩阵 (conf=0.548)



全局: TP = 192、FN (漏检) = 185、FP (误检) = 105。 **关键事实:**

1. **几乎零类间混淆**: 17 类对角全正、无跨类格 (GT 要么正确检出要么漏检) —— RT-DETR 的类判别能力远强于 yolo11s (079 曾记录 22 个错类, heidian→wy 等);
2. **失败模式 = 漏检**: FN 集中于小目标——bd 31/44 (70%)、heidian 26/39 (67%)、wy 29/39 (74%)、bmss 29/44 (66%), 落入背景列 (与 11g 样图一致);
3. **FP 105**: 误检框分散于小/中类, 多为低置信同类噪声 (对应 11g 误检图);
4. **数据改进启示**: 瓶颈是**小目标检出**而非**类别判别** → 强化 11c/11e 的小目标原位池 + 难例挖掘方向, 类别混淆无需处理。

架构融合研究（一）：P2 高分辨率层 —— 可行性与计算约束

动机：RT-DETR 混淆矩阵显示失败模式 = 小目标漏检（FN 185：bd 31/44、hei 26/39、 wy 29/39、bmss 29/44）；1280 下 bd/hei 仅 7-15px，P3(stride 8) 特征已不足。

设计：RT-DETR backbone 的 P2(stride 4) 特征（HGStem 输出）已存在但 head 未用；最小侵入 yaml 接入：upsample X3 → concat P2 → RepC3 → decoder 输入 4 尺度（P2,P3,P4,P5）。

可行性验证（本报告写作时实测）：

- 1. RTDETRDecoder 的 nl = len(ch) + input_proj 按通道自动扩展——**原生支持 4 尺度**；
- 2. 前向 640 / 1280 均通过，输出 6 解码层 × 300 query × (box4 + cls17)；
- 3. 训练冒烟（coco8 @640，1 epoch）loss 正常反传；参数 32.0M → 34.8M。

计算约束（关键发现）：

变体	GFLOPs @640	相对原版	Item4 影响
RT-DETR-L（原版）	26	1.0×	基准 29.7fps 估
RT-DETR-L + P2（全接入）	219	8.5×	不可行 （估 <5fps）

P2 特征图在 1280 输入 = 320×320，token/卷积量爆炸（新增 97% 计算）→ **P2 全接入否决**。

架构融合研究（二）：P2 修正方案与实验矩阵

方案 A（推荐）：P2 辅助监督头 —— 训练侧在 P2 上挂轻量检测头做 aux loss，推理端只用 decoder（P3-P5），**零推理开销**（Item4 不变）；P2 梯度监督主网小目标表征。风险：091（yolo11s + P2 head）历史为负，但 RT-DETR 解码器全局建模语义不同，需重验。

方案 B：P2 轻量接入 decoder（1×1 proj、无 RepC3）——CCFF 跨尺度 token 仍 3×，仅 RT-DETR-R18 级可试（速度余量）。

方案 C：multi_scale 训练（零架构改动，RT-DETR 未试；YOLO 049 曾负）。

方案	实现	Item4	预期	风险
A P2 aux 头	yaml + loss 补丁	不变（推理无 P2）	bd/hei R 升 5-10pp	091 历史负信号
B P2 轻接入	yaml（R18 级）	R18 保 30fps 待测	bd/hei 直接可见 P2	计算仍高、工程复杂
C multi_scale	仅训练参数	不变	小目标尺度多样性	049 负信号（YOLO）

决策点：A（保 Item4，训练侧）与 B（R18 精度优先）需取舍；建议先 A 后 B。数据侧与 small 原位池（11e）可叠加。下一步：实现方案 A 的 yaml + aux loss 补丁并本地冒烟。

结论与交付建议

场景	模型	R@0.25	速度 (估)	Item4	评价
V1 精度优先	096 RT-DETR-L @1280	0.7565	29.7fps	边缘	最强召回；交付前必测目标机
V1 速度优先	095 RT-DETR-L @640	0.7070	32.9fps	边缘 PASS	降 5pp 换余量；仍需实测
V1 对照	019 yolo11s + cls_w	0.6213	119.5fps	PASS	YOLO 路线最优（速度安全）
V3 重建	080 配置 yolo11s @1280	0.6038*	—	—	B 级；需重建数据后复核

待办：① V3 重建后以同 script 复核 080/096；② RT-DETR-R18@1280（速度 × 精度）；③ 交付前在目标机（3080）实测 Item4；④ scripts/r25_manual.py 已作为独立审计匹配器入库。

附录：数据来源与口径复现验证

复现验证（本报告写作时，用仓库 `scripts/eval_scoring.py` 对幸存权重重跑）：

模型	历史记录	本次复算	一致性
004 yolo11s @640	0.6140 / 0.5453 / 0.5776	0.6140 / 0.5453 / 0.5776	逐位一致
076 yolo11s @1280	0.6353 / 0.4320 / 0.5143	0.6354 / 0.4321 / 0.5144	一致 (± 0.0001)
097 RT-DETR-L @1280	0.7137 / 0.3939 / 0.5076	0.7159 / 0.3925 / 0.5070	一致 (± 0.002)

来源清单：

- 1. 001-057 R/P/maxR: `outputs/report_retest_selfval_conf025.csv`, `final_selfval_delivery.csv` (A)
- 2. 076/078/095/096/097 逐类 maxR 与 best_F1: `outputs/eval_scoring/*/scoring_report.{txt,csv}` (A/S)
- 3. 076/097 本次复算: `outputs/eval_scoring/{076,097}_reeval_conf025/` (A)
- 4. 速度: `outputs/eval_scoring/{004,095,096,097}*/fps_benchmark.json` + reeval 报告 (A)
- 5. V3 (079-093): 当时 `eval_scoring` 会话输出 (B; 原资产已清理)
- 6. 审计工具: `scripts/r25_manual.py` (`conf` ≥ 0.25 + IoU0.5 + 17 类宏平均独立实现)

NOTE[注：另以手写匹配器与 `ultralytics val(conf=0.25)` 交叉验证，两者与 `eval_scoring` 存在 4-6pp 的匹配实现差异（TP 分配策略不同）——以 `eval_scoring` 为唯一正式口径。]

结语

1. **最强模型**: RT-DETR-L @1280 (096, V1 $R@0.25 = 0.7565$) ——但 Item4 处于边缘 (29.7fps 估)。
2. **可靠路线**: yolo11s (019/076 系列, 0.62-0.64 且速度无忧)。
3. **最重要的方法论修正**: 训练侧“尺度对齐 + 原位池 + 架构变更”值得继续; 背景抑制 (070/071)、长尾加权 (092/093)、P2 (091) 方向已关闭。
4. **数据治理**: 历史全部数值可复现 (eval_scoring 在仓库); V3 重建时保留数据 + 权重 + 报告 三者于仓库内, 避免 B 级黑箱再次出现。