


织物缺陷检测：从数据难点到方法选择

17 类缺陷 · 2048×2048 原图 · RT-DETR 基线对比

大学生竞赛素材 · 2026-09

任务定义

- 织物表面缺陷检测：17 类，框级定位 (bbox)
- 原图 2048×2048 ，训练 1445 / 验证 181 / 测试 181
- 推理分辨率 1280 (640/1280 训练模型不能混用)
- 只提交训练权重，禁用 TTA / 集成等推理端手段



数据难点（三条）

难点 1：类别极不均衡 + 部分类样本极少


- bd/heidian 是“白点/黑点”，GT 仅 44/39 个实例
- wy 污印 39 / zmt y 37 / lj 12 / yy 压印仅 2 个

难点 2：小目标尺度失配

- 中位 bd 15px、heidian 12px (2048)
- 1280 推理下仅 9.4 / 7.4px，小于 40px 特征网格
- mAP50 仅 0.15-0.29（小目标定位差）

难点 3：跨类视觉相似 / 漏标注

- heidian→wy、zmt y→bmss 等易混淆
- val 标注稀疏：FP 高 $\neq$ 纯背景，压背景会压真阳性




数据处理（三步）

[

1. **尺寸对齐**：训练统一 1280，消除 640/1280 尺度失配崩溃
 2. **增强池扩充**：实例中心 patch (bd/hei 583) + 合成池 + wavelet
 3. **无泄漏划分**：8:1:1 图级重划，类分层迭代 (val 每类 ≥ 8)
- 教训：跨集验证有 80.9% 泄漏，任何跨划分数值作废


注：增强池提升小目标召回，但整体 mAP 收益有限——增强不解决尺度表征]

训练数据池构成（v1 系，总 7401 张）




方法对比：YOLO 基线 vs RT-DETR 最优

方法	R@0.25	mAP50
yolo11s 基线 004	0.614	0.605
yolo11s+cls 019	0.621	0.577
RT-DETR-L 096	0.757	0.677
RT-DETR-L 097	0.716	0.636



R@0.25 对比 (v1 val)

RT-DETR 架构与创新点




图源：RT-DETR 官方架构图 (arXiv:2304.08069, 经 Ultralytics 文档引用)；P2 辅助头为本工作新增

基线： HGNetv2 P2-P5 → 混合编码器 (AIFI + 跨尺度融合) → IoU-aware query 选择 → 解码器 (6 层×300 query, P3/P4/P5) → 框 + 类别

创新： **P2AuxHead** (P2/4 轻量头, 训练侧, 推理零开销)

RT-DETR 训练配置与效果


项	值
模型	RT-DETR-L 32M, COCO 预训练
数据	b-final-v3 (2838 池)
训练	1280, batch8, 72ep, AdamW 1e-4
口径	self-val + conf 0.25 + IoU 0.5
R@0.25	0.716 (vs YOLO 0.62)
mAP50	0.636
FPS	30 (3080 估, 临界)




conf-R/P 曲线

检出与漏检案例（左 GT / 右 预测）

检出与漏检案例（左 GT / 右 预测）




检出与漏检案例（左 GT / 右 预测）



bd / heidian 小目标检出 + 大目标检出 (conf 0.55)




检出与漏检案例（左 GT / 右 预测）



漏检（bd/hei 7-20px）与误检——小目标仍是主短板

DEIMv2: Real-Time Detection Meets DINOv3



图源: DEIMv2 官方论文 arXiv:2509.20787 (Spatial Tuning Adapter 架构图)

架构路线 (S/M/L/X 档): DINOv3 自监督预训练 ViT → **STA (Spatial Tuning Adapter)** → 混合编码器
→ 简化解码器 → Dense O2O 训练

STA 解决什么: DINOv3 只有**单尺度**输出 (ViT 16×16 patch) → STA 用轻量卷积把 $1/8$ 、 $1/16$ 、 $1/32$ 三个尺度的细粒度细节“注入”各层, 无需改动预训练 backbone

论文三个创新:


1. **STA 空间调谐适配器**: 单尺度→多尺度, 语义+细节互补
2. **高效解码器**: 4 层×300 query, cross-attn 简化
3. **升级版 Dense O2O**: Mosaic+MixUp+CopyBlend 密集监督

DEIMv2 Model Zoo 与本职工作选型

档位	COCO AP	参数	backbone	适合
N	43.0	3.6M	HGNetv2	轻量
S	50.9	9.7M	DINOv3	速度友好
M	53.0	18.1M	DINOv3	均衡
L	56.0	32.2M	DINOv3	本文选择
X	57.8	50.3M	DINOv3	精度极限

为什么选 DINOv3-L:

- 织物缺陷是弱纹理细粒度判别 (wy 污印 ↔ zmtly 脏印) ——自监督 DINOv3 表征的强项
- 与 RT-DETR-L 同为 32M 参数档，公平对比
- 从 COCO 预训练权重 -t 微调 (分类头重映射 80→17 类)



训练配方：从踩坑到官方配方


项	首次尝试 102	最终 103
lr	1e-4（保守）	官方 5e-4 分层
分类头	80 类（漏配）	17 类
batch	4	4×累积 8=32
增强	无 Mosaic/MixUp	官方 Dense O2O
输入归一化	缺 Normalize	ImageNet mean/std

对照实验证明配方价值：

- 102（同数据，错误配方）：AP50 0.594，R@0.25 0.706
- 103（官方配方）：AP50 **0.708**，R@0.25 **0.775**

结论：SOTA 架构只有配上官方训练配方才能兑现——直接照抄保守参数会浪费 7pp

结果：DEIMv2 DINOv3-L 全面领先




指标	103	096
R@0.25	0.775	0.757
P@0.25	0.460	0.403
AP50	0.708	0.676
AP50-95	0.500	0.462
best-F1	0.704 (conf .47)	—
bd 小点	0.614	0.432

新增最好：bd 白点 0.217→0.614（三轮迭代 +39.7pp）；zmt/heidian/wy 弱纹理类全部改善

检测效果（左 GT / 右 预测， $\text{conf}=0.47$ 平衡点）

检测效果（左 **GT** / 右 **预测**， $\text{conf}=\mathbf{0.47}$ 平衡点）




检测效果（左 GT / 右 预测，conf=0.47 平衡点）



jt 接头完美检出 / pd 含纸张阴影误检 / wy 小点类别混淆



检测效果（左 GT / 右 预测，conf=0.47 平衡点）



heidian+HD 横档对齐 / zmtty 密集印点合并现象——碎片化标注的合并是主要残差来源

结论

1. 数据集核心难点：**类别不均衡 × 小目标尺度 × 类间相似**
2. 数据处理：1280 对齐 + 增强池 + 无泄漏 8:1:1 重划
3. 方法迭代：YOLO 0.621 → RT-DETR-L 0.757 → **DEIMv2 DINOv3-L 0.775** (R@0.25 宏平均, +15.4pp vs 基线)
4. 经验：SOTA 架构必须配官方训练配方 (lr 分层 / 17 类头 / 梯度累积 / Dense O2O)；短板 wy 污印与 zmt y 密集印点为下一轮数据侧方向